

От ноутбука до multi-GPU

Инфраструктура и софт для локального запуска LLM

Практический алгоритм выбора инструментов для локального запуска LLM (август 2026)

+ Что запускать, на чём, сколько стоит и как обслуживать



Где уже используется AI?

AI в 2026 году вышел далеко за пределы чата. Сценарии, которые уже работают:

- + **Код** — генерация, ревью, тесты
- + **Текст и документы** — чаты, ИИ-поиск и поиск по документации
- + **Агенты** — автоматизация рабочих задач
- + **Транскрибация и голос** — Whisper, голосовые ассистенты
- + **Медиа** — фото и видео

Кто использует AI во всех сценариях? Ежедневно?



Сколько стоит «бесконечный» AI?

Подписки ChatGPT:

	Free	Go	Plus	Pro
Цена	\$0	\$8/мес.*	\$20/мес.	\$100 или \$200/мес.
Основная модель	GPT-5.6 Luna	GPT-5.6 Luna	GPT-5.6 Sol	GPT-5.6 Sol / Sol Pro
Reasoning / Think	Luna Think	Luna Think	Sol — Medium/High	Sol — до Extra High + Sol Pro
Обычные текстовые чаты	Безлимит*	Безлимит*	Безлимит*	Безлимит*
Лимит основной модели	Ограниченный для Free	Выше Free	Существенно выше	5× / 20× относительно Plus
Контекст / память	Ограниченные	Расширенные	Более расширенные	Максимальные
Deep Research	Ограниченный	Ограниченный	Расширенный	Максимальный
Codex	Ограниченный	Ограниченный	Расширенный	Максимальный
Скорость ответа	Ограниченная	Ограниченная	Быстрая	Быстрая
Приоритет при высокой нагрузке	✗	Выше Free	✓	✓
Реклама	Может быть	Может быть	Нет	Нет

429: Too Many Requests



Too many requests in 1 hour. Try again later.

Как часто вы сталкивались с этой ошибкой?



Models API: оплата за токены

Альтернатива подпискам — оплата только за использованные ресурсы (API).

Модель	Input/1M Tokens	Output/1M Tokens
GPT-5.6 Sol	~\$4.00	~\$20.00
GPT-5.6 Terra	~\$2.00	~\$12.00
Claude Sonnet 5	~\$2.00	~\$10.00
Claude Opus 5	~\$5.00	~\$25.00

1M токенов = ~1500 страниц A4 с текстом 12pt шрифта Arial (англ.яз.)

Подписка или Models API?

Оплата

Кто пытался оплатить зарубежный AI-сервис с юрлица в РФ за последний год?






Models API: оплата за токены

Альтернатива подпискам — оплата только за использованные ресурсы (API).

Модель	Input/1M Tokens	Output/1M Tokens
GPT-5.6 Sol	~\$4.00	~\$20.00
GPT-5.6 Terra	~\$2.00	~\$12.00
Claude Sonnet 5	~\$2.00	~\$10.00
Claude Opus 5	~\$5.00	~\$25.00
GLM 5.1 (Cloud.ru)	~\$3.00	~\$10.00

Риск утечки

Кто хотя бы раз отправлял код, пароли, логи или персданные в ChatGPT/Claude?



Зачем локально? Три драйвера в РФ

1 Контроль

- + Версия модели, квантизация, промпты — без сюрпризов от провайдера
- + "Купил и забыл"

2 Безопасность и закон

- + ФЗ-152, КИИ, коммерческая тайна. Утечка = риск

3 Автономность

- + Изолированно
 - + Без лимитов
 - + Без риска блокировки
-

Модели



Классы моделей

+ Tiny ($\leq 4B$)

- + Edge-устройства, on-device запуск, простые задачи
- + Qwen3.5 4B, Phi-5 Mini, Gemma 4 E4B
- + VRAM: < 8 ГБ

+ Small (4B–40B)

- + Лучший баланс для агентов и кодинга
- + **Qwen3.8-27B**, **Qwen3.6-35B-A3B**, Laguna XS 2.1, North Mini Code 1.0, Ornith 1.5, Muse-Glimmer-30B
- + VRAM: > 16 ГБ

+ Medium (40B–150B)

- + Сложная логика, продвинутый кодинг, отличный reasoning
- + Laguna S 2.1, MAI-Code-1-Flash
- + VRAM: > 32 ГБ

+ Large ($> 150B$)

- + Серверный уровень, замена проприетарным API
 - + DeepSeek-V4-Pro, Tencent Hy3, Nemotron 3 Ultra, Kimi K3, Qwen 3.8 Max, Minimax M3
 - + VRAM: > 128 ГБ
-

Как выбирать модель

BY CAPABILITY

-  **Coding**
Генерация кода и отладка
-  **Reasoning**
Логика, планирование и решение задач
-  **Research**
Анализ и исследовательские задачи
-  **Tool Calling**
Вызов функций и использование инструментов
-  **Writing**
Создание контента и креативное письмо
-  **Long Context**
Понимание длинного контекста
-  **Chat**
Разговор и следование инструкциям

BY MODALITY

-  **Image Understanding**
Визуальное понимание и анализ изображений
-  **Image Generation**
Модели text-to-image
-  **Video Generation**
Создание и редактирование видео с помощью ИИ
-  **Speech**
Преобразование текста в речь и синтез голоса
-  **Transcription**
Распознавание речи и преобразование аудио в текст
-  **Computer Use**
Автоматизация задач на ПК и в браузере

BY INDUSTRY

-  **Math & Science**
Математическое мышление и решение задач
-  **Finance & Accounting**
Финансовый анализ и экономическое мышление
-  **Legal**
Правовые знания и юриспруденция
-  **Healthcare**
Медицинские знания и сфера здравоохранения
-  **Roleplaying**
Симуляция персонажей и ролевые сценарии

Оценивайте не только оценку по бенчам, но и производительность на вашем железе, лицензию и реальные отзывы по деградации при квантизации.

Софт для запуска моделей



Софтверный стек

+ Личное использование:

- + `Ollama` (самый простой старт), `LM Studio` (удобный GUI).

+ Максимальный контроль / Apple / CPU:

- + `llama.cpp` (база для большинства инструментов).

+ Production / multi-user:

- + `vLLM` (PagedAttention) или `SGLang` (особенно для agentic + prefix-heavy + MoE).

+ Apple Silicon:

- + `MLX` + `Ollama`.

Инфраструктура для Аудио/Фото/Видео: `Whisper`, `Stable Diffusion`, `ComfyUI`



Инфраструктура вокруг

- + **Воспроизводимость:** Docker.
 - + **Память и RAG:**
 - + Vector DB: Qdrant, pgvector, Chroma
 - + Агентная память: Hindsight, mem0
 - + **Шлюз:** OpenAI-compatible endpoint (LiteLLM, Portkey, Bifrost, CLIProxyAPI)
 - + Подключение агентов и мониторинг запросов (токены/с, latency)
 - + **MCP**
 - + **WebUI:** OpenWebUI,
 - + **Квантизация ([разбираемся с суффиксами](#)):**
 - + `Q4_K_M` - золотой стандарт баланса качества и размера:
 - + 70B: 130GB (fp16) -> 40GB (q4)
 - + `MLX-4bit` — Apple
 - + `NVFP4` - новые NVIDIA (архитектура Blackwell)
-

Железо

Железо — 4 ценовые категории

1 Бюджет (до 100 тыс. ₽)

- + RTX 3060 12 ГБ, мини-ПК с NPU, мощный CPU
- + Тянет: 7–14B

2 Народный (100–200 тыс. ₽)

- + RTX 3090 24 ГБ, Mac M4 Pro 36 ГБ
- + Тянет: 14–32B

3 Рабочая станция (200–600 тыс. ₽)

- + RTX 5090 32 ГБ
- + 128 ГБ: NVIDIA DGX Spark, Mac Studio, AMD Ryzen Max+ 395
- + Тянет: 70B + несколько сервисов

4 Enterprise (от 600 тыс.)

- + Multi-GPU, A100/H100, Huawei Atlas 300i/Duo, RTX PRO 6000
 - + Тянет: тяжёлые MoE + высокий параллелизм и контекст
-

Детали по железу

- + **RTX 3090 24 ГБ б/у**: лучшее соотношение цена/VRAM (≈ 3.8 тыс. ₽/ГБ).
 - + **RTX 5090 32 ГБ**: $\approx 390\text{--}490$ тыс. ₽, bandwidth 1792 ГБ/с, TDP 575 Вт.
 - + **Apple Silicon (Mac Studio, Mac Pro)**: unified memory = запуск моделей, не влезających в одну GPU.
 - + *Нюанс*: bandwidth ниже топовых RTX $\rightarrow$ медленнее decode.
 - + **AMD Ryzen Max+ 395**: тоже unified memory.
 - + **Multi-GPU**: электричество + требования к охлаждению и БП.
-

Краткие рекомендации «что брать прямо сейчас»

- + **Один разработчик / ноутбук:**

- + Mac M4 Pro 24+ ГБ + Qwen3.6-35B-A3B + MLX/Ollama.

- + **Команда / небольшой сервер:**

- + 1–2× RTX 5090 32 ГБ + Qwen3.8-27B + vLLM/SGLang.

- + **Корпоративный контур:**

- + Multi-GPU A100/H100 80+ ГБ + vLLM/SGLang.

Итоги

- + Локальный LLM — это про **контроль, безопасность и предсказуемость**, а не про «максимальное качество любой ценой».
 - + В 2026 году открытые модели (особенно Qwen и DeepSeek-линейки) уже закрывают **80–90 % повседневных IT-задач** на доступном железе.
 - + Главное — считать экономику и выбирать стек под реальную нагрузку.
-

Q&A
