

От ноутбука до multi-GPU

Инфраструктура и софт для локального запуска LLM

Практический алгоритм выбора инструментов для локального запуска LLM (август 2026)

+ Что запускать, на чём, сколько стоит и как обслуживать

А зачем?

Где уже используется AI?

AI в 2026 году вышел далеко за пределы чата. Сценарии, которые уже работают:

- + **Код** — генерация, ревью, тесты
- + **Текст и документы** — чаты, ИИ-поиск и поиск по документации
- + **Агенты** — автоматизация рабочих задач
- + **Транскрибация и голос** — Whisper, голосовые ассистенты
- + **Медиа** — фото и видео

Кто использует AI во всех сценариях? Ежедневно?

Варианты оплаты LLM-моделей


Почему я рассказываю про локальный запуск



1. Подписка

\$0-\$200 / мес

ChatGPT и аналоги




- ✓ Готовый UI, голос, агенты, Deep Research
- ✓ Фиксированная цена при умеренном использовании
- ✗ Динамические лимиты и 429
- ✗ Риски утечки данных, сложности оплаты из РФ



2. Models API

~\$2-\$30 / 1M токенов

Оплата за токены




- ✓ Pay-as-you-go: платите только за использованное
- ✓ Полный контекст, автоматизация, агенты, batch
- ✗ Быстро дорожает при активном чате / агентах
- ✗ Те же риски данных и сложности оплаты из РФ



3. Аренда GPU

~\$0.1-\$4 / час

GPU-as-a-Service
для open-weight моделей



- ✓ Любая open-weight модель и квантизация
- ✓ Нет утечки данных к OpenAI / Anthropic
- ✗ Нужно самому поднимать стек и DevOps
- ✗ Переменное качество и сетевые задержки



Ключевой вывод

Каждый вариант имеет свои плюсы и минусы.

Локальный запуск LLM даёт максимальный контроль, приватность и предсказуемую стоимость при высокой нагрузке.



Контроль данных



Предсказуемая стоимость



Нет скрытых лимитов




Лучше для РФ

SHUT UP AND



TAKE MY MONEY!


Советские стандарты качества



Оптимизация расходов на AI



Kimi-K3 (2.8T params) локально — удовольствие не из дешёвых



80 × RTX 5090

в 10 серверах по 8 карт
2.56 TB VRAM (GDDR7)



800GbE

чтобы скрепить
этот адский оркестр



~60 кВт

потребление системы
= обесточите подъезд 😞



~80°C

в комнате
за 1 минуту



32–39 млн ₽

только за GPU

≈ 11 300 ₽ в день на электричество



Нет 80 друзей с RTX 5090 и подстанции во дворе?

\$99 в месяц за облако — лучшее предложение в жизни 😎

Ещё одна причина запускать LLM локально

Abliterated (uncensored) open-weight модели и LoRA-модели



Abliterated (uncensored) open-weight модели

Модели без корпоративных safety-фильтров



Быстро и эффективно

- ✓ Без большого дообучения
- ✓ Сохраняет знания и reasoning

Применяется для:

- ✓ Red-teaming и исследования
- ✓ Creative / roleplay / NSFW
- ✓ Независимость от провайдеров



Популярные базы 2026:

Qwen3.6/3.8 • Gemma 4 • Llama 3.x • GLM 5.1 • DeepSeek-дистилляты и др.



LoRA-модели

Лёгкая кастомизация под ваши задачи

Как создаётся LoRA-модель



Что даёт LoRA



Нужно меньше VRAM и времени



Несколько адаптеров и переключение



Доменные модели, uncensored версии, специализация



Легко распространять (адаптеры весят МБ-ГБ, а не десятки ГБ)

Варианты 2026

LoRA (16-bit)
QLoRA (4-bit + LoRA)
DoRA • LoRA+ • SDFT

Инструменты:

Unsloth • Axolotl • TRL
Hugging Face PEFT
MLX-LoRA и др.

Почему это важно
при локальном запуске



Полный контроль над отказами модели



Свобода для исследований и red-teaming



Creative, roleplay, NSFW и другой uncensored контент



Domain-адаптация без цензуры и под ваши данные



Независимость от политики провайдеров

Зачем локально? Три драйвера в РФ

1 Контроль

- + Версия модели, квантизация, промпты — без сюрпризов от провайдера
- + "Купил и забыл"

2 Безопасность и закон


- + ФЗ-152, КИИ, коммерческая тайна. Утечка = риск

3 Автономность

- + Изолированно
 - + Без лимитов
 - + Без риска блокировки
-

Выбор модели

Трудности выбора модели



Сколько всего моделей на Hugging Face?

The screenshot shows the Hugging Face homepage with a dark theme. At the top left is the Hugging Face logo and name. To its right is a search bar with the placeholder text "Search models, datasets, users...". On the top right, there is a "Models" link with a cube icon. Below the search bar, there is a navigation bar with tabs: "Main" (selected), "Tasks", "Libraries", "Languages", and "Lib". To the right of these tabs is a "Filter by name" button. In the center of the page, a large white text overlay reads "Models 3,038,676", which is enclosed in a red rectangular box. Below this, there are task categories: "Text Generation", "Any-to-Any", "Image-Text-to-Text", and "Image-to-Text". On the right side, a model card for "zai-org/GLM-5.3" is partially visible, showing its task as "Text Generation", size as "753B", and update time as "Updated 3 days ago".

Hugging Face Search models, datasets, users... Models

Main Tasks Libraries Languages Li Filter by name

Models 3,038,676

Tasks

Text Generation Any-to-Any Image-Text-to-Text Image-to-Text

zai-org/GLM-5.3
Text Generation • 753B • Updated 3 days ago

КЛАССИФИКАЦИЯ LLM ДЛЯ ЛОКАЛЬНОГО ЗАПУСКА

1. РАЗМЕР (ПАРАМЕТРЫ) Tiny ≤ 4B On-device, Edge Быстрые ответы, базовые задачи, tool-calling Small 4B – 40B Баланс качества и скорости Агенты, коддинг, RAG, повседневные IT-задачи Medium 40B – 150B Сложная логика, продвинутый коддинг, длинный контекст, многошаговое reasoning Large > 150B Серверный уровень, замена проприетарным API, высокий параллелизм, длинный контекст	2. АРХИТЕКТУРА Dense Все параметры активны для каждого токена MoE (Mixture of Experts) Активируются только часть экспертов (активные параметры) Hybrid Комбинация Dense и MoE для баланса качества и эффективности	3. НАЗНАЧЕНИЕ General Универсальные задачи Coding Генерация и анализ кода Reasoning Логика, математика, планирование Multimodal Текст, изображение, аудио, видео Domain-specific Специализированные области (медицина, финансы, право и др.)	4. TRAINING ORIGIN GPPT (General-Purpose Pre-Training) Обучение на широких данных для общих задач DSPT (Domain-Specific Pre-Training) Обучение на данных конкретной предметной области POST-TRAINING SFT Supervised Fine-Tuning RL Reinforcement Learning (RLHF / RLAI) Distill Knowledge Distillation	5. МОДАЛЬНОСТЬ Текст (Text) Изображение (Image) Аудио (Audio) Видео (Video) Мультимодальная (Multi) Комбинация модальностей
--	---	---	--	--

6. КВАНТИЗАЦИЯ, КОНТЕКСТ И ТРЕБОВАНИЯ К VRAM					Размер (параметры)				Контекст (Context Length)
Квантизация	Биты / вес	Качество (относительно FP16)	Память ↓	Рекомендуется для	Tiny (≤4B)	Small (4B–40B)	Medium (40B–150B)	Large (>150B)	
Q2_K_M	~2.2 – 2.8 bit	~70–80%	~4x	Эксперименты, прототипы, макс. экономия VRAM	≤ 4B VRAM: ≤ 4 ГБ	4B – 40B VRAM: 6 – 10 ГБ	40B – 150B VRAM: 16 – 32 ГБ	> 150B VRAM: 64 – 96 ГБ	8K – 32K
★ Q4_K_M (рекомендуется)	~4.0 – 4.5 bit	~90–95%	~2x	Оптимальный баланс качества и памяти	≤ 4B VRAM: ≤ 6 ГБ	4B – 40B VRAM: 8 – 18 ГБ	40B – 150B VRAM: 24 – 48 ГБ	> 150B VRAM: 96 – 160+ ГБ	16K – 128K
Q5_K_M	~5.0 – 5.5 bit	~95–98%	~1.6x	Чуть выше качество, умеренный расход VRAM	≤ 4B VRAM: ≤ 8 ГБ	4B – 40B VRAM: 12 – 24 ГБ	40B – 150B VRAM: 32 – 64 ГБ	> 150B VRAM: 128 – 192+ ГБ	32K – 128K+
FP16 / BF16	16 bit	100%	1x	Макс. качество, минимум компромиссов	≤ 4B VRAM: 10 – 16 ГБ	4B – 40B VRAM: 20 – 40+ ГБ	40B – 150B VRAM: 64 – 120+ ГБ	> 150B VRAM: 160 – 320+ ГБ	64K – 1M+

7. ПРИМЕРЫ СОВРЕМЕННЫХ LLM (АВГУСТ 2026)			ПРИМЕЧАНИЯ	
Qwen3.6-35B-A3B MoE Размер: 35B total / ~3B active Назначение: General, Coding, Agentic Контекст: 128K Квантизация: Q4_K_M (рекоменд.) VRAM (Q4_K_M): ~14 – 18 ГБ	Llama 4 Maverick Dense Размер: 70B Назначение: General, Reasoning, Coding Контекст: 128K Квантизация: Q4_K_M (рекоменд.) VRAM (Q4_K_M): ~28 – 40 ГБ	DeepSeek-V4*Pro MoE Размер: 671B total / ~37B active Назначение: Reasoning, Coding, Agentic Контекст: 256K Квантизация: Q4_K_M (рекоменд.) VRAM (Q4_K_M): ~120 – 160+ ГБ	- VRAM указана для 1 GPU. - Реальные требования зависят от архитектуры, реализаций (gguf, exl2, awq), объёма кэша KV и batching. - MoE: смотрим на активные параметры (active params), а не total params.	

Где посмотреть рейтинги моделей?

При выборе модели для реальных задач стоит опираться на независимые лидерборды:

arena.ai

Слепые A/B-тесты (LMSYS Chatbot Arena). Специализированный лидерборд для webdev и fullstack-разработки.

llm-stats.com

Сводная статистика и актуальный рейтинг лучших моделей для написания и рефакторинга кода.


artificialanalysis.ai

Независимый бенчмарк качества (intelligence breakdown), скорости инференса (токены/сек) и стоимости.

На что обращать внимание:

- + • **Coding & Agentic benchmarks:** оценивайте тесты на реальном коде, а не синтетические метрики.
 - + • **Соотношение качество / размер:** для локального запуска критичен баланс VRAM и скорости.
-

GPT-5



74.9 Swe-Bench Verified
GPQA Diamond 85.7
MMMU 84.2

Qwen 3.6 27B



77.2 Swe-Bench Verified
GPQA Diamond 87.8
MMMU 82.9

Софт

Софтверный стек для локального запуска LLM

Инструменты и где их лучше использовать



Ollama



Быстрый старт
для разработчика



LM Studio



Удобный GUI
и сравнение моделей



llama.cpp



Максимальный контроль
и портативность



MLX
(+ mlx-lm)



Максимальная скорость
на Apple Silicon

LLM



High concurrency
для production



SGLang



Agentic & prefix-heavy
RAG, structured output, MoE

Выбор по сценарию



Ноутбук / один разработчик

Ollama, LM Studio
или llama.cpp



Небольшой сервер / команда

Ollama, LM Studio
При росте нагрузки —
vLLM или SGLang



Production / multi-user

vLLM — общий случай
SGLang — agentic, prefix-heavy,
MoE, structured output



Apple Silicon (Mac)

MLX через Ollama /
LM Studio — максимум
скорости



OpenAI-совместимые
API у всех серверов



Легко разворачиваются
в Docker



Выбор по задачам:
single-user vs multi-user



Широкая совместимость
с экосистемой

Железо


4 ценовые категории

- 1 Ультрабюджет (до 100 тыс. ₽)
 - 2 Народный (100–200 тыс. ₽)
 - 3 Рабочая станция (200–600 тыс. ₽)
 - 4 Enterprise (от 600 тыс. ₽)
-




Сравнение сборок для AI и локальных LLM

NVIDIA DGX Spark vs MiniPC (AMD AI 395+ MAX) vs Mac Studio Max

	NVIDIA DGX SPARK  AI-суперкомпьютер на вашем столе	MINIPC WITH AMD AI 395+ MAX  Мощный мини-ПК на архитектуре AMD	MAC STUDIO MAX  Производительность Mac в профессиональном формате
 Процессор	NVIDIA Grace (20 ядер ARM)	AMD Ryzen AI 9 HX 370 (12 ядер / 24 потока)	Apple M2 Ultra (24-ядерный CPU)
 Графика / AI-ускоритель	NVIDIA Blackwell GPU (6144 CUDA, Tensor Cores 5-го поколения) 128 ГБ унифицированной памяти	AMD Radeon 890M (16 CU) + XDNA 2 NPU (50 TOPS)	Apple M2 Ultra GPU (76-ядерный) + 32-ядерный Neural Engine
 Память	128 ГБ LPDDR5x (унифицированная)	До 128 ГБ LPDDR5X-7500 (унифицированная)	64 / 128 / 192 ГБ (унифицированная)
 Накопитель	1 ТБ / 4 ТБ NVMe (PCIe 4.0)	До 4 ТБ NVMe (PCIe 4.0)	До 8 ТБ SSD (PCIe 4.0)
 Энергопотребление	~170 Вт (под нагрузкой)	~65–90 Вт (под нагрузкой)	~120–150 Вт (под нагрузкой)
 ОС / ПО	NVIDIA DGX OS (Ubuntu-based) + NVIDIA AI Software Stack	Windows 11 / Linux (поддержка ROCm, PyTorch, LM Studio и др.)	macOS Sonoma (оптимизировано для ML / Metal / Core ML)
 Ключевые возможности	• Оптимизирован для AI / ML / LLM • Высочайшая пропускная способность памяти • Поддержка NVIDIA CUDA, TensorRT, NIM • Идеален для разработчиков и исследователей	• Отличное соотношение цена/производительность • Встроенный NPU для AI-задач • Поддержка локальных LLM и генерации изображений • Гибкость апгрейда и подключения периферии	• Максимальная производительность в экосистеме Apple • Отличная энергоэффективность и тишина • Оптимизация под Core ML и Metal • Идеален для творческих задач + AI
 Скорость генерации (пример: Llama 3.1 70B Q4_K_M)	до 45–60 токенов/сек (в зависимости от модели и настроек) Очень высокая скорость	до 8–15 токенов/сек (в зависимости от модели и настроек) Средняя скорость	до 20–30 токенов/сек (в зависимости от модели и настроек) Высокая скорость
Тесты на основе LM Studio / llama.cpp / MLX. Скорость может варьироваться в зависимости от модели, квантизации и настроек.			
 Поддерживаемые LLM (примеры)	✓ Llama 3 / 3.1 (8B – 405B) ✓ Mixtral 8x7B / 8x22B ✓ Qwen 2 (7B – 72B) ✓ Yi, Mistral, Gemma, Phi и др. ✓ Поддержка больших контекстов (до 200K+)	✓ Llama 3 / 3.1 (8B – 70B) ✓ Gemma 2 (9B – 27B) ✓ Mistral / Mixtral (7B – 22B) ✓ Phi-3, Qwen 1.5 / 2 (7B – 32B) ✓ Оптимально: 7B – 30B модели	✓ Llama 3 / 3.1 (8B – 70B) ✓ Mistral (7B – 22B) ✓ Gemma 2 (9B – 27B) ✓ Phi-3, Qwen (7B – 32B) ✓ Оптимально: до 70B (Q4 / Q5)
 Что выбрать?	NVIDIA DGX Spark – для тех, кому нужна максимальная производительность в AI и работа с самыми большими моделями.	MiniPC (AMD AI 395+ MAX) – лучший выбор по соотношению цена/производительность для локальных задач и экспериментов.	Mac Studio Max – для пользователей macOS, которым важна стабильность, экосистема и высокая производительность.

Почему не серверные GPU?





80 000 ₽

RTX 3090 Palit GamingPro 24Gb
(Скупка,trade-IN)

В наличии: несколько




Скидка на доставку

126 462 ₽ + 600 Б >

до 100% кешбэк от Альфа-Банка >

Apple Mac Studio M1 Max 32/512



270 000 ₽

Beelink gtr9 pro ai max 395 128gb (strix halo)

В наличии: несколько



280 600 ₽

Apple Mac Studio (M4 Max, 2025) 128
гб, 2 тб SSD




495 000 ₽

до 300 000 ₽ займы на что угодно >

Суперкомпьютер nvidia DGX Spark в
наличии

В наличии: несколько



669 999 ₽

до 300 000 ₽ займы на что угодно >

MacBook Pro 16 M5 Max 128Gb/2Tb
nano

Краткие рекомендации

- + **Один разработчик / ноутбук:**
 - + Mac M4 Pro 24+ ГБ + Qwen3.6-35B-A3B + MLX/Ollama.
 - + **Команда / небольшой сервер:**
 - + 1–2× RTX 5090 32 ГБ + Qwen3.8-27B + vLLM/SGLang.
 - + **Корпоративный контур:**
 - + Multi-GPU A100/H100 80+ ГБ + vLLM/SGLang.
-

Итоги

Итоги

- + Локальный LLM — это про **контроль, безопасность и предсказуемость**, а не про «максимальное качество любой ценой».
 - + В 2026 году открытые модели уже закрывают **80% повседневных IT-задач** (см. harness).
 - + Главное — считать экономику и выбирать стек под реальную нагрузку.
-



Контакты автора

TODO



